

RNN


RNN은?

RNN (Recurrent Neural Network) - 순환신경망


- sequence 모델 : 입/출력을 시퀀스 단위로 처리 → 맥락/순차가 있는 series 데이터를 사용
- 은닉층에서 활성화 함수를 지닌 값이 출력층 방향으로 가는 Feed Forward Neural Network와 달리 은닉층에서 활성화 함수를 지닌 값이 출력층으로도 가고, 다음 은닉층의 입력으로도 가는 특징을 가진 RNN → 순환



은닉층에서 활성화함수를 통해 결과를 출력하는 역할 : cell (=RNN cell, 메모리 cell) → 이전 값을 기억하는 메모리 역할
→ cell은 각 시점 (time step)에서 이전 시점의 메모리 셀에서 나온 값인 은닉 상태 (hidden state)를 자신의 입력으로 사용하는 재귀적 활동을 함



- RNN은 입출력 길이를 다르게 설계 할 수 있음
 1. one-to-many : image captioning에 사용 (한 이미지 입력에 대해 사진의 제목 출력)
 2. many-to-one : 감성 분류, 스팸 메일 분류에 사용
 3. many-to-many : 챗봇, 번역기 등에 사용




RNN 수식

현재 시점 t에서의 은닉 상태값을 ht라 할 때, 메모리 셀이 ht를 계산하기 위해 총 두 개 가중치가 필요 - Wx, Wh

- Wx : 입력층에서 입력값을 위한 가중치
Wh : 이전 시점 t-1의 은닉 상태값인 ht-1을 위한 가중치

은닉층 : $h_t = \tanh(W_x x_t + W_h h_{t-1} + b)$
출력층 : $y_t = f(W_y h_t + b)$

- 활성화 함수 F : 하이퍼볼릭탄젠트(비선형 함수)
Wh : 출력층에서 출력값을 위한 가중치



단어 벡터의 차원이 d, 은닉 상태의 크기가 Dh라 했을 때, 각 벡터의 행렬 크기 :

$$\tanh \left(\begin{matrix} W_h \\ D_h \times D_h \end{matrix} \times \begin{matrix} h_{t-1} \\ D_h \times 1 \end{matrix} + \begin{matrix} W_x \\ D_h \times d \end{matrix} \times \begin{matrix} x_t \\ d \times 1 \end{matrix} + \begin{matrix} b \\ D_h \times 1 \end{matrix} \right) = \begin{matrix} h_t \\ D_h \times 1 \end{matrix}$$

RNN의 한계


단순한 형태의 RNN을 **바닐라 RNN**이라고 함

바닐라 RNN의 단점 : **장기 의존성 문제 = long-term dependency**

- ⇒ time step이 길어질 수록 앞의 정보가 충분히 전달되지 못함
- ⇒ 즉 문장이 길 수록 단어를 예측하기 어려움

Deep Recurrent Neural Network (깊은 순환 신경망)


- 다수의 은닉층을 가짐



은닉층이 2개

Bidirectional Recurrent Neural Network (양방향 순환 신경망)

- 이전 시점의 메모리 셀뿐만 아니라 이후의 메모리 셀로도 예측할 수 있음
- 아래 그림의 주황색 메모리 셀이 앞 시점의 은닉 상태, 초록색 메모리 셀이 뒤 시점의 은닉 상태를 전달 받음



파이썬으로 RNN 구현

```
import numpy as np

timesteps = 10 # input의 길이
input_dim = 4 # 단어 벡터 차원
hidden_size = 8 # 메모리 셀 용량

inputs = np.random.random((timesteps, input_dim))
hidden_state_t = np.zeros((hidden_size))

Wx = np.random.random((hidden_size, input_dim))
Wh = np.random.random((hidden_size, hidden_size))
b = np.random.random((hidden_size))

total_hidden_state = []

for input_t in inputs:
    output_t = np.tanh(np.dot(Wx, input_t) + np.dot(Wh, hidden_state_t) + b)
    total_hidden_state.append(output_t)
    hidden_state_t = output_t

total_hidden_states = np.stack(total_hidden_state, axis = 0)
print(total_hidden_states)
```

출력

```
[[0.83213084 0.94014708 0.94293618 0.9482776 0.95779251 0.92466643
0.96846002 0.89850639]
[0.99987603 0.99998275 0.99969981 0.99997101 0.99999835 0.99998026
0.99999751 0.99988123]
[0.99990898 0.99999164 0.99963683 0.99996511 0.99999688 0.99998957
0.99999931 0.99977258]
[0.99984286 0.99997693 0.99917386 0.99989104 0.99999534 0.99997721
0.99999673 0.99971713]
[0.99992776 0.99998457 0.99962919 0.99997349 0.99999718 0.99999537
0.99999898 0.9998552 ]
[0.9999532 0.99998916 0.99971282 0.99998716 0.99999909 0.99999549
0.99999896 0.99990327]
[0.99994704 0.9999913 0.99987952 0.99999177 0.99999922 0.99999642
0.99999942 0.99995932]
[0.99985877 0.99997671 0.99938228 0.99992068 0.99999566 0.99998501
0.99999743 0.99979908]
[0.99978089 0.99996169 0.99931316 0.9998622 0.99999456 0.99997645
0.99999499 0.99984046]
[0.99992143 0.99999046 0.99952873 0.999966 0.99999789 0.99998829
0.9999989 0.9997608 ]]
```